



UNIVERSIDAD CATÓLICA
de Colombia



UNIVERSIDAD CATÓLICA
de Colombia

Vigilada Mineducación

Uso de Herramientas Informáticas para proyectos de Big Data

Diego Alberto Rincón Yáñez
darincon@ucatolica.edu.co



Introducción a la Computación Distribuida

Supercomputación

- Es lo mas grande y rápido en computación en este preciso momento.
- Es también la computadora mas grande y rápida del mundo es este instante.
- Hay una regla?, un supercomputador es mínimo 100 veces mas rápido que el PC mas rápido del mundo



Introducción a la Computación Distribuida

Supercomputación

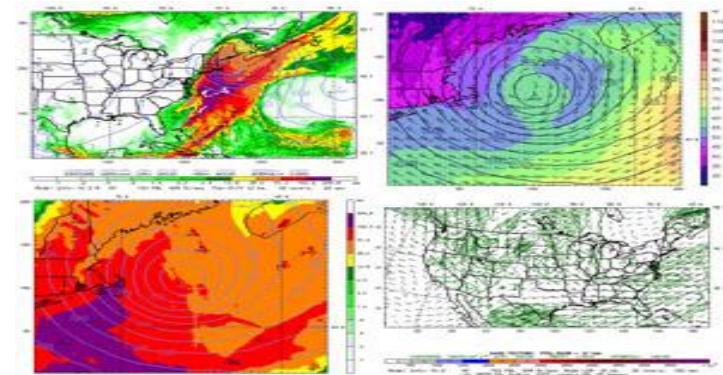
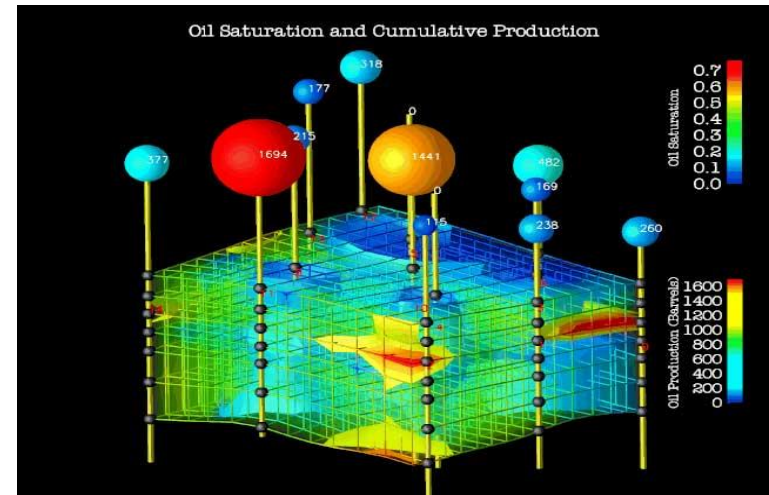
- La supercomputación también se conoce como:
- Computación de Alto Rendimiento - High Performance Computing (HPC).
- High End Computing (HEC).
- Ciberinfraestructura - Cyberinfrastructure (CI).



Introducción a la Computación Distribuida

Estos procesos podrían ser:


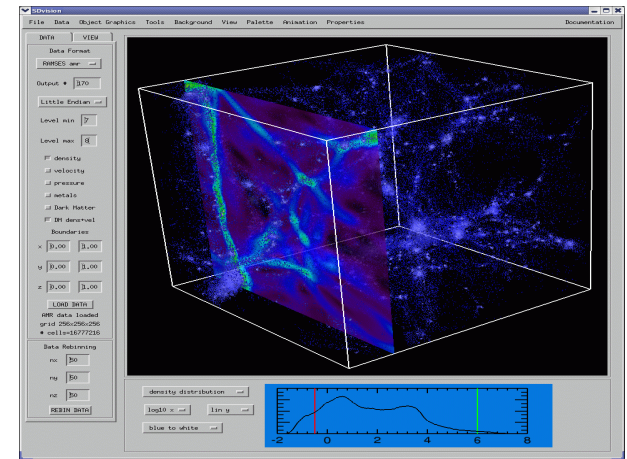
- Simulación de fenómenos físicos, tales como:
- Pronóstico del tiempo
- Formación de Galaxias
- Administración de las reservas de petróleo



Introducción a la Computación Distribuida

Estos procesos podrían ser:

- Minería de datos:
- Secuenciación de genes
- Procesamiento de señales
- Detección de las tormentas que pueden producir tornados





Introducción a la Computación Distribuida




Ejemplo

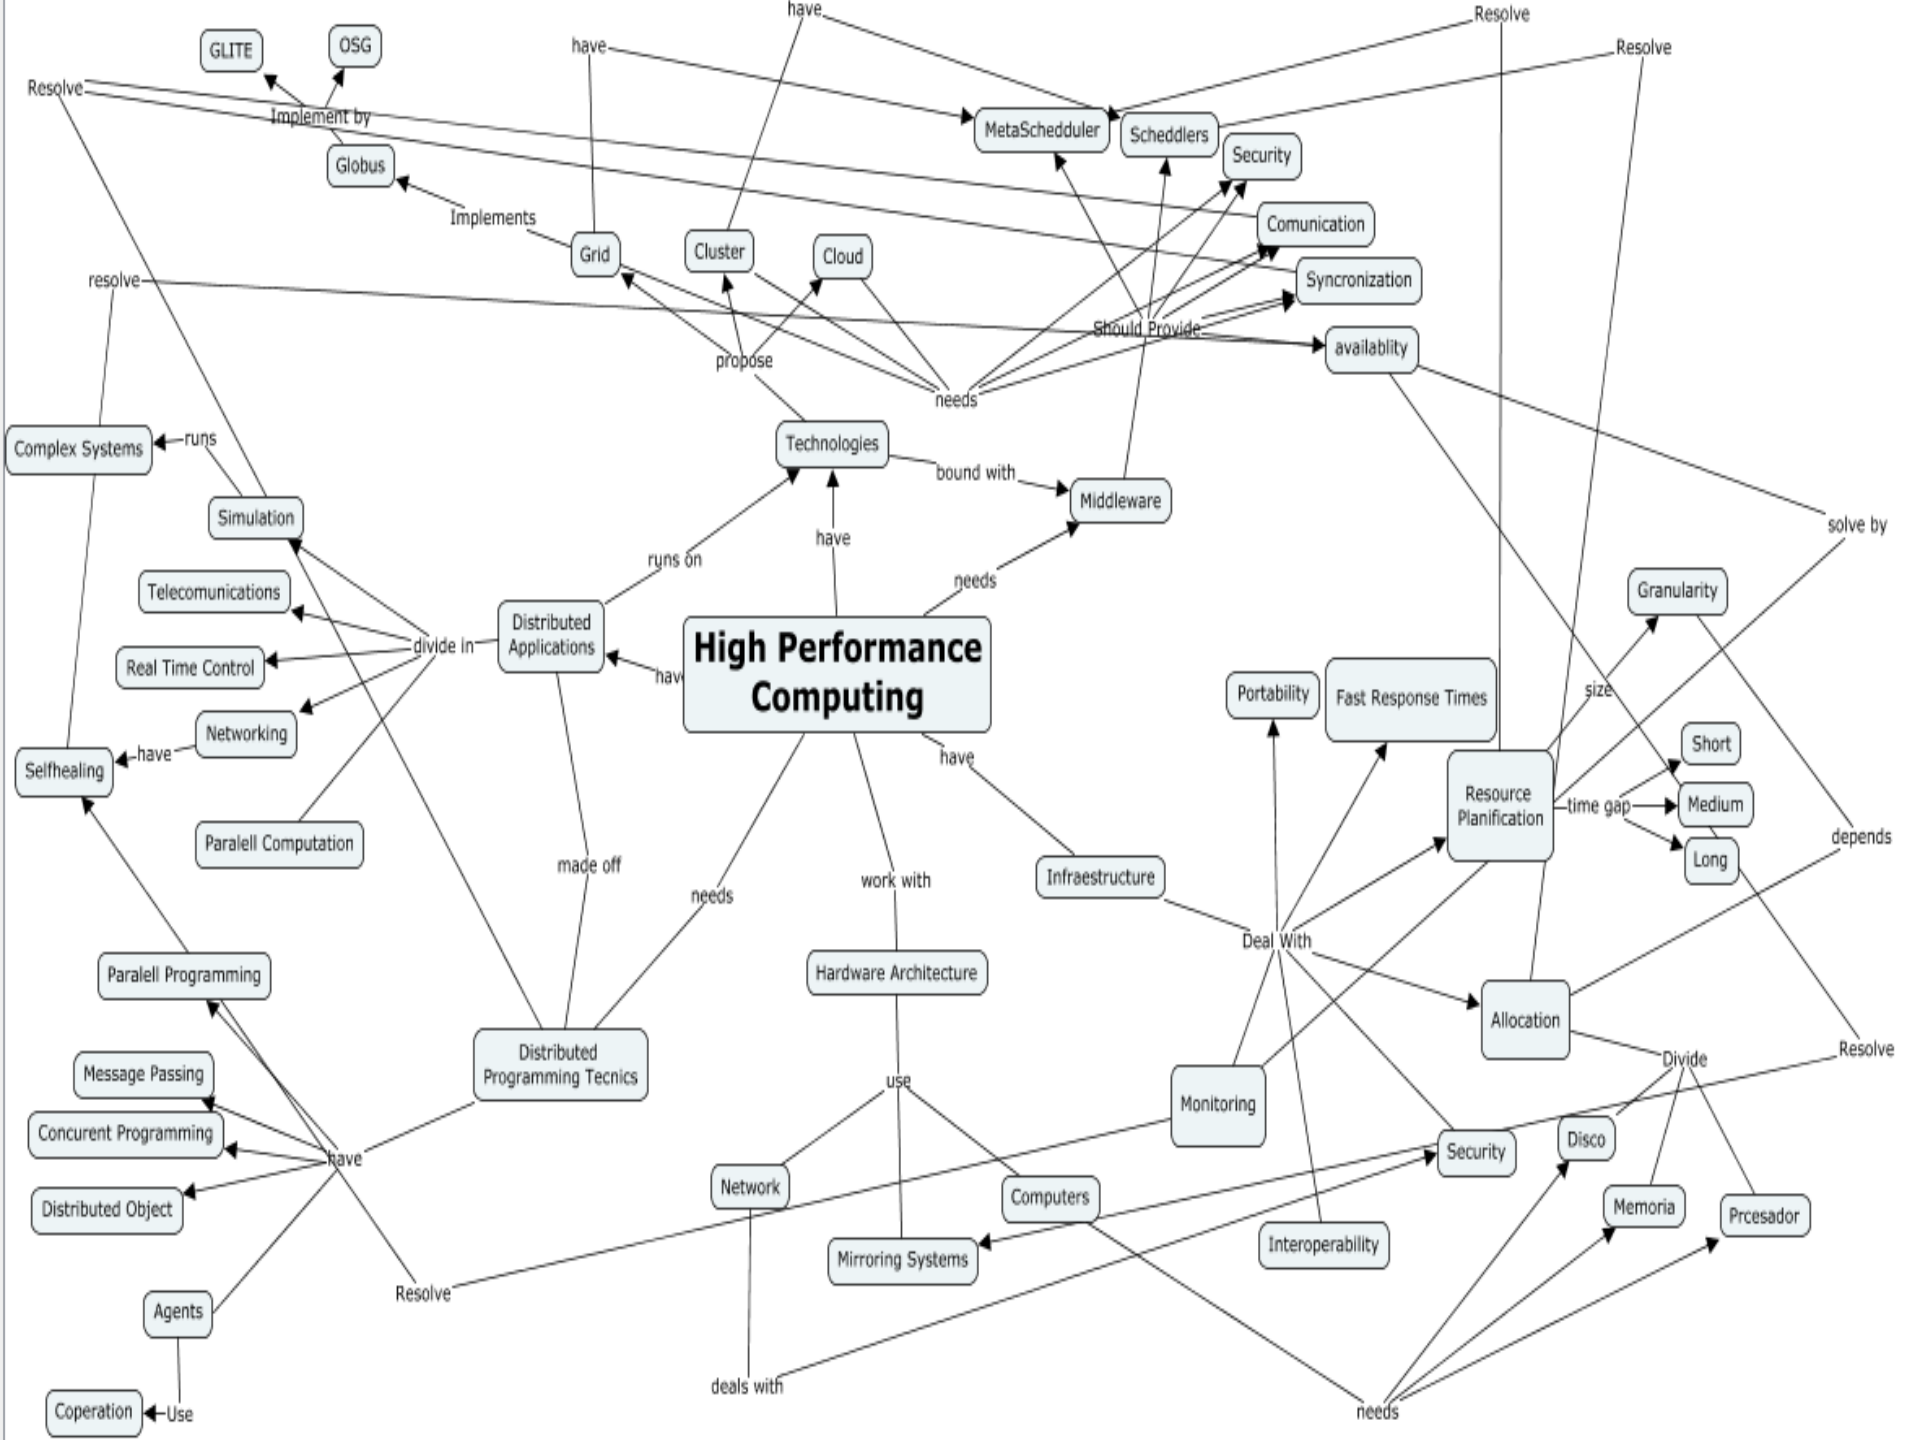
En el laboratorio Argonne el supercomputador Blue Gene/P permite ver la simulación de la explosión de una estrella supernova, este proceso en un PC tardaría 22 millones de horas el evento tarda solo 5 segundos.

- Este supercomputador tiene mas de 160.000 procesadores



[Video](#)





Introducción a la Computación Distribuida

Computadora Paralela: Máquina con dos o más procesadores que pueden trabajar simultánea y/o coordinadamente.

Memoria Compartida: En una máquina paralela existe una sola memoria que puede ser accedida por todos los procesadores.

Memoria Distribuida: Cada uno de los procesadores de un multiprocesador tiene asociado a él una unidad de memoria.

Conceptos básicos

Computación paralela

Máquina con dos o más procesadores que ejecutan trabajos simultáneamente compartiendo los recursos de hardware de la propia máquina.

Computación distribuida

Múltiples máquinas separadas físicamente conectadas a través de la red de datos que permite ejecutar trabajos dividiendo los problemas grandes en tareas mas pequeñas distribuidas entre las máquinas conectadas.



Qué es un CLUSTER ?

- Es un conjunto de máquinas conectadas a través de la red.
- Permite que el usuario final perciba al CLUSTER como una sola máquina de grandes prestaciones computacionales.
- Permite la escalabilidad del sistema mediante la adición de nuevo hardware.
- Requiere de software que coordine el trabajo entre las máquinas.
- Esta compuesto por un *nodo principal* que coordina la ejecución de trabajos entre los *nodos trabajadores* y *nodos cliente* para el envío de trabajos.



Tipos de CLUSTER

1. **Alto rendimiento (HPC)** ejecutan tareas que requieren de alta capacidad computacional (procesamiento, memoria, almacenamiento). No garantiza la disponibilidad.
2. **Alta disponibilidad (HAC)** garantiza la prestación continua del servicio y la recuperación ante posibles fallos.
3. **Alta eficiencia (HTC)** su objetivo es el de ejecutar la mayor cantidad de trabajos en el menor tiempo posible.



Clasificación de los CLUSTER

De acuerdo a su configuración de hardware.

- **Homogéneos:** iguales tipos de tecnologías y plataformas.
- **Heterogéneos:** distintos tipos de tecnologías y plataformas.

De acuerdo al nivel de dedicación del sitio.

- **Dedicado:** su funcionamiento es exclusivo para prestar servicios al CLUSTER.
- **No dedicado:** su destinación al CLUSTER es parcial de acuerdo a la disponibilidad de la máquina (oportunista).



Para que sirve un CLUSTER

- Para ejecutar trabajos complejos que requieren de altos volúmenes de recursos de cómputo (procesamiento, memoria y almacenamiento) que no pueden ser ubicados en máquinas individuales.
- Estos trabajos pueden dejarse ejecutando durante varios días gracias a la *disponibilidad* del CLUSTER mientras se realizan los cálculos y procesamientos solicitados. Posteriormente el usuario final puede recuperar los resultados obtenidos.



Para que no sirve un CLUSTER

- No es posible ejecutar cualquier tipo de aplicaciones, estas deben estar diseñadas para aprovechar las características del CLUSTER.
- No está diseñado para obtener resultados en “tiempo real”, todo depende del flujo de trabajo al cual esté sometido el CLUSTER HTC.
- Los trabajos ejecutados no pueden interactuar directamente con el usuario a través de un GUI.



Ambientes de programación

- La programación es dependiente de la arquitectura (32/64bits, otros) y sistema operativo.
- Para que un problema sea distribuido se debe hacer uso de un sistema de colas y/o librerías especiales:
 - PVM (*parallel virtual machine*) usada especialmente en cluster con nodos heterogéneos (arquitectura del procesador, sistemas operativo, entre otras), y pertenecientes a diferentes dominios de red.
 - MPI (*Message passage interface*), librería usada para cluster homogéneos.






Alto Desempeño vs Paralelizar



Solución No-Paralela

- Programa Secuencial

```
while (!fin) {  
    bufer = recoger();  
    guardar(bufer);  
    result = calcular(bufer);  
    informar(result);  
}
```

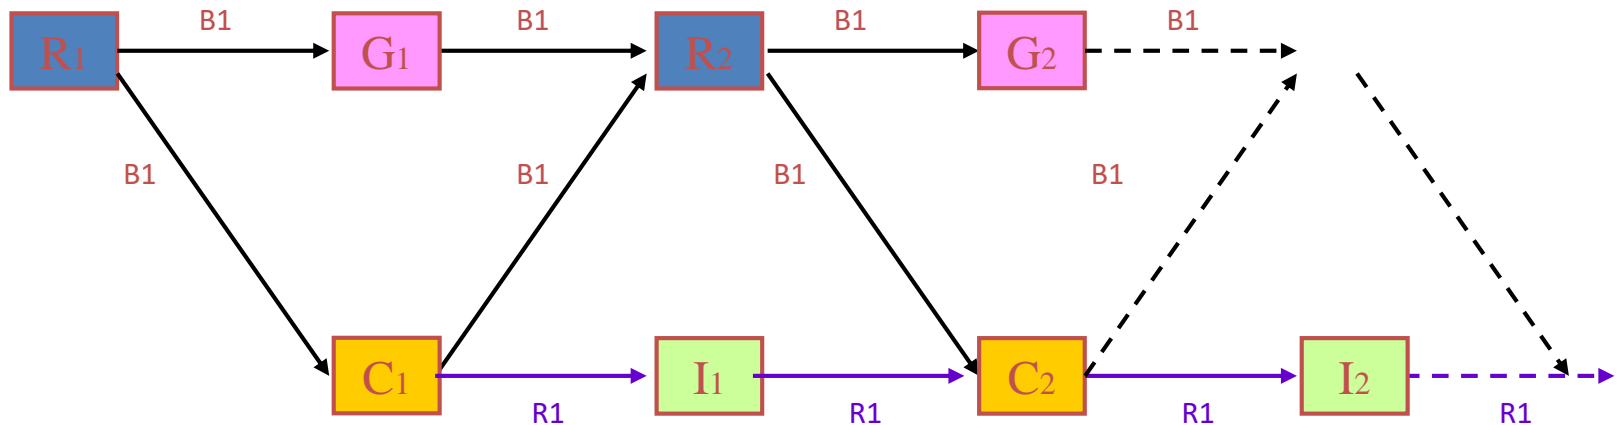


Simplicidad vs. **Ineficiencia**



Solución Paralela Base

- Procesos Paralelos y Precedencia Relativa

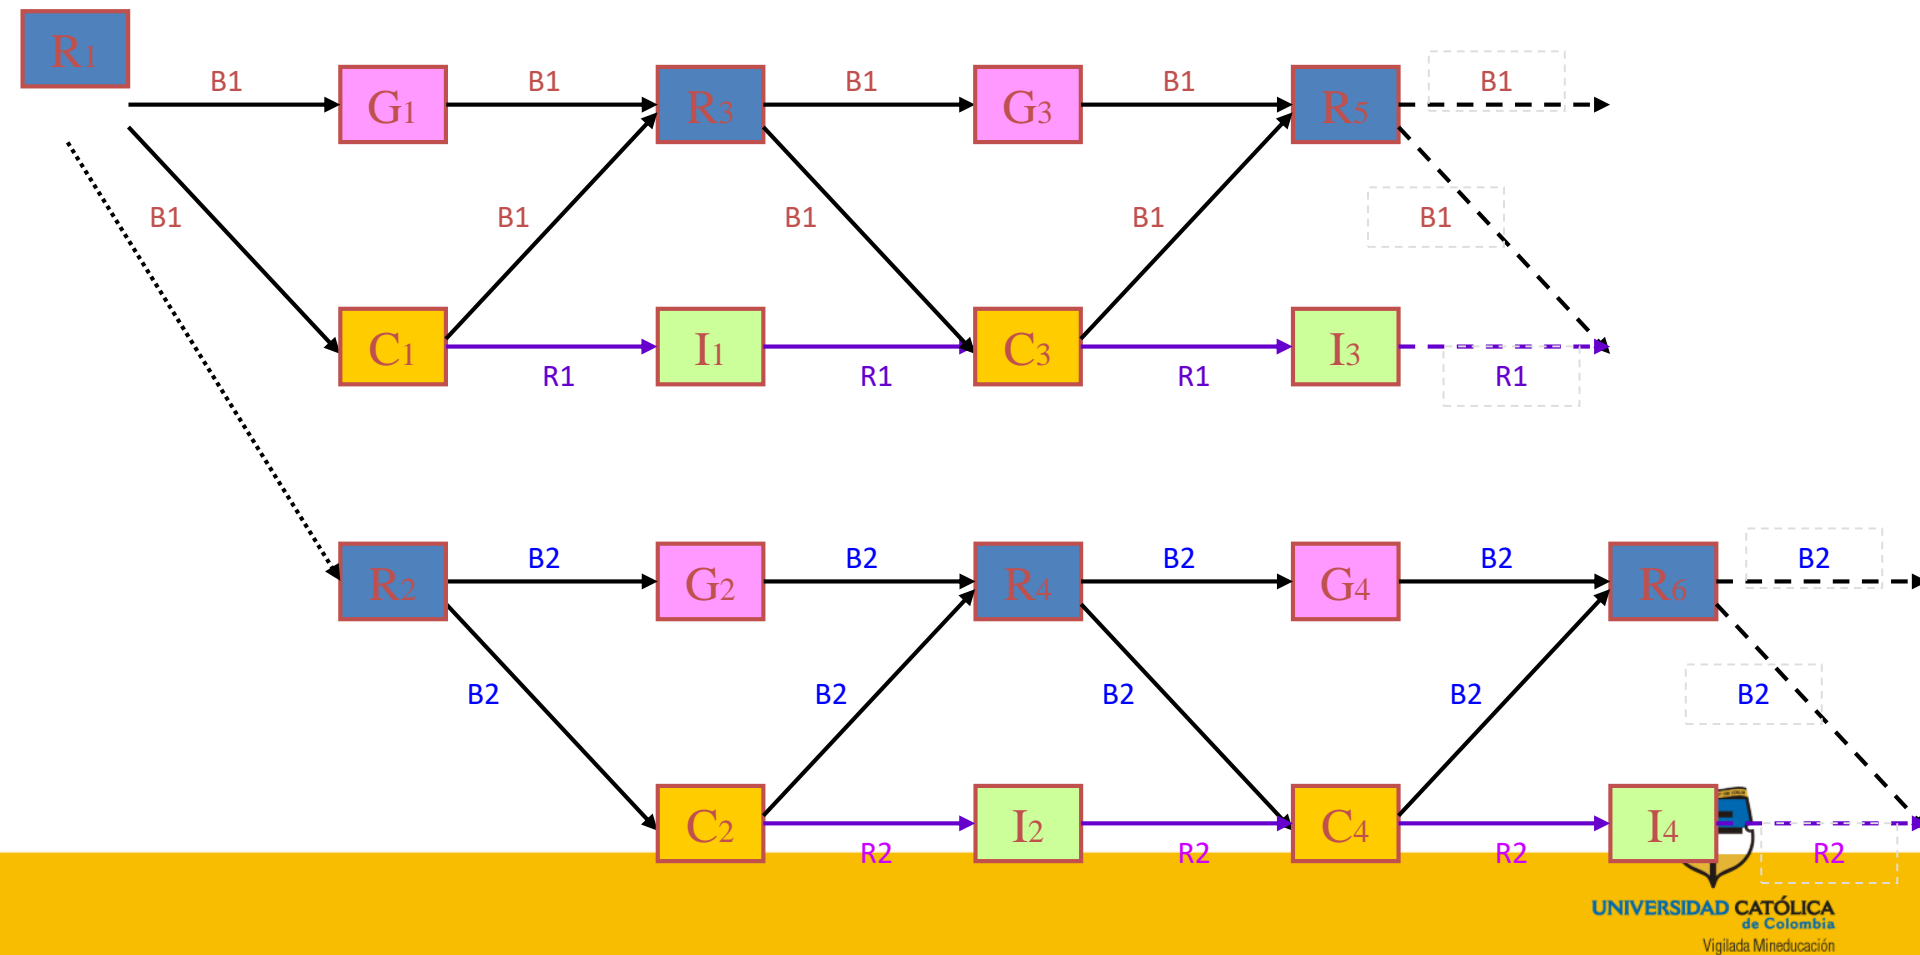


Paralelismo vs. **Sincronización**




Solución Más Paralela


- Procesos Paralelos y Memoria




Tipos Base de Concurrency




Paralelismo de
Datos



Paralelismo
Funcional



Pipeline



¿Preguntas?

Diego Alberto Rincón Yáñez MCSc.
Twitter: @d1egoprog.

